

# OBOE PAPER SUMMARY

Ziyu Zhong

2022 年 6 月 8 日

## 1 思维导图

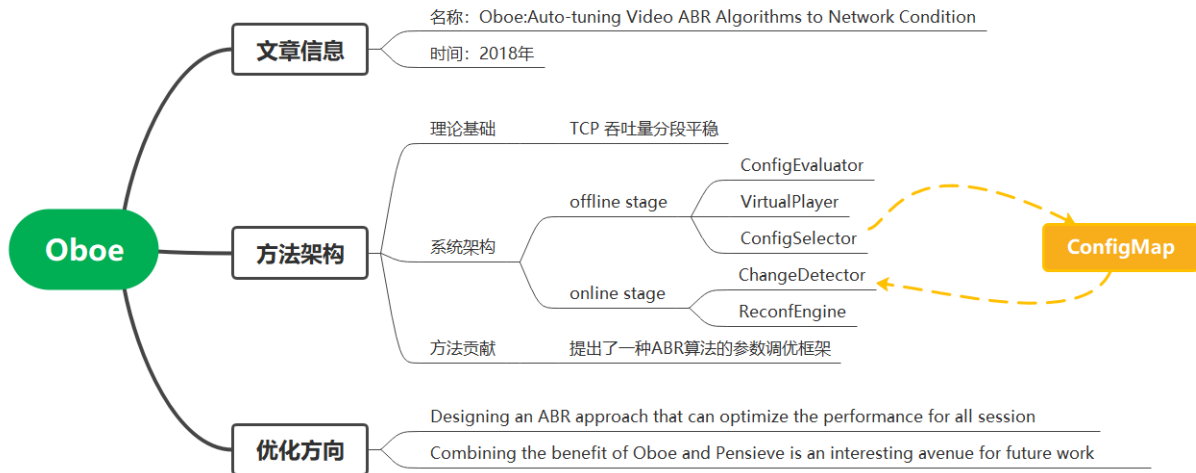


图 1: 思维导图

## 2 文章逻辑

### 2.1 文章信息

- 名称: Oboe:Auto-tuning Video ABR Algorithms to Network Conditions
- 作者:
- 日期: 2018 年

### 2.2 提出的问题

ABR Algorithms have limited dynamic range: they do not perform uniformly well across the range of network conditions seen in practice because their parameters are sensitive to throughput variability

也就是说当前的众多自适应码率算法因为其参数对网络吞吐量敏感, 所以并不能在各种网络条件下都表现最优。这也表明了在当前方法下, 算法性能仍然存在提升空间。同时作者也通过对以往方法实验, 说明了参数选取对性能有很大的影响。

## 2.3 提出的方法

### 2.3.1 前置条件

TCP connections are well-modeled as traversing a piecewise-stationary sequence of network states: the connection consists of multiple non-overlapping segments where each segment is in a distinct stationary network state, where each segment is stationary and often lasts for tens of seconds or minutes. Moreover, the throughput in each segment may be modeled as an i.i.d process.

More recent work also shows that TCP throughput is well modeled as a Markov process, each of whose states may be modeled as a Gaussian distribution.

作者对于 Oboe 的设计是基于前人对于 TCP 连接建模的研究结论, 也就是 TCP 连接可以分成多段不重叠的独立平稳的网络状态, 这样我们就可以通过每个分段的统计特征去寻找当前算法下的最优参数。这也是这种方法能获得性能增益的理论基础。

由于每个 TCP 连接分片可以建模成独立同分布的高斯过程, 我们可以使用  $\langle \mu_s, \sigma_s \rangle$  对状态建模。

### 2.3.2 方法架构

Oboe pre-computes, offline, the best parameter configuration for a given ABR algorithm. it does this by subjecting the algorithm, for each state, to different parameter values, and picking the one that results in the best performance. Then, during video playback, Oboe continuously uses a change-point detection algorithm to detect changes in network state and selects the parameter identified by the offline analysis as best for the current state. Thus, if a video session encounters varying network state during its lifetime, Oboe automatically specializes the ABR parameter to each one.

总体上看, Oboe 的方法架构分为了两个大的阶段, 一个是离线阶段 (offline stage), 另一个是在线阶段 (online stage) 接下来分别说明其工作方式。

- 离线阶段: 如图 1 所示为 Oboe 的在线阶段工作示意图




Figure 3—The logical diagram of the offline pipeline used by Oboe

图 2: offline

- ConfigEvaluator: 从人工合成的 trace 中提取出  $\langle \mu_s, \sigma_s \rangle$  形式的数据 (ADF 假设试验)。

- VirtualPlayer: 模拟虚拟的播放场景, 省略真实中下载和播放的过程, 输入 throughput trace, 输出 QoE metrics。将每种配置对应的 QoE 表现记录下来, 给到 ConfigSelector。
- ConfigSelector: 根据从 VirtualPlayer 拿到的信息, 选取每种状态下最佳的配置。最终得到网络状态和算法参数对应的 ConfigMap。
- Publisher Spec.: 发布者可以根据自己的偏好来调整 QoE 的评估方式。

- 在线阶段: 如图 2 所示为 Oboe 的在线阶段工作示意图




Figure 4—Logical diagram of Oboe's online pipeline

图 3: online

- ChangeDetector: 当观测到 throughput trace 的统计特性发生明显变化时, 马上更新当前网络状态
- ReconfEngine: 根据新的网络状态  $s$ , 在 ConfigMap 中以  $s$  为圆心,  $r$  为半径选取最保守的策略。

## 2.4 方法的贡献

个人角度理解, 本文的方法提出一个通用的 ABR 算法的优化框架, 基于现有的多种方法对参数敏感的特点出发, 结合前人对于 throughput trace 统计特性的研究, 将某个时间片的 throughput 的统计特性作为一个状态, 基于大量生成的 trace 模拟生成最优“状态-动作”查找表, 在应用时再根据查找表作出最优决策。

和 Pensieve 对比, 两者都针对泛化性能有提升, 都有从数据中学习经验的过程。个人觉得不同在于, Pensieve 的底层逻辑是强化学习, 其基本性能取决于学习算法优劣, 而 Oboe 则是一个人工设计的参数选取策略, 其性能应该会受制于 ABR 算法本身的优劣, 所以 Oboe 一定程度上是在榨干已有算法的潜在性能, 将 fixed parameters 变为 dynamic parameters.

## 2.5 可优化的方向

Online stage deployment? client side or server side better? The detailed comparison of these choices is left to future work.

Whether Oboe can tune all algorithms and all parameters is an open question. It is also unclear if Oboe can directly augment Pensieve. Combining the benefit of Oboe and Pensieve is an interesting avenue for future work.

As the experiments results shows, Oboe improve most but not all sessions relative to the algorithm it tunes. In some sessions, it meets degradation. Generally, designing an ABR approach that can optimize the performance for all sessions is a hard problem that needs more research.

### 3 遗留的问题

在 online stage 的时候完全是依赖于 offline stage 生成的 ConfigMap 进行决策, 那么是不是意味着 offline 在模拟真实场景要建模足够准确, 那么如何评估建模方式, 哪些因素需要考虑, 哪些因素可以忽略简化, 现在学界是否已经有一个比较通用并验证可靠的建模方式。再考虑实际应用中, 如果出现了一些新的未知状态, 是否就会带来性能的损失, 这方面问题是否值得考虑?

另外还有一点疑问, 我们知道 ConfigMap 是离散的, 并且文中已经对 trace 的 state 进行了量化大小的测试, 得出进一步量化的性能提升并不大。而在实际中的 trace 状态是连续的, 所以在实际通过 ConfigMap 寻找策略时, 文中提到了半径  $r$  为范围选取最保守策略, 但似乎没给出定量性的说明, 比如  $r$  的取值范围, 以及选最保守是否就对应了当前 QoE 下的最优选择, 也就是说关于这个策略选取是否有继续压榨性能的可能?

该方法由于 ChangeDetector 的存在, 是否有滞后性问题 (没细看)